

Article 4 : Une nouvelle direction

1. Introduction

a. Synthèse du parcours

Cet article marque un tournant dans le projet de prédiction du prix du Bitcoin documenté par une série d'articles.

Pour rappel, la démarche présentée s'est articulée de la façon suivante :

- Article 1 : Pose du cadre méthodologique, et de l'hypothèse testée : « Est-il possible de prédire les prix futurs à partir des prix passés seuls ? »
- Article 2 : Construction des fondations. Création d'un pipeline de données (API Binance), et Analyse Exploratoire (EDA). Résultats clés : marché fragmenté, dominance retail, et surtout ruptures de régimes fréquentes.
- Article 3 : Cœur de l'expérimentation. Modélisation ML (LSTM, GRU, SimpleRNN) en s'approchant de condition réelle (walk-forward). Conclusion : L'hypothèse initiale est invalidée.

b. Discussion : Pourquoi l'approche série temporelle atteint ses limites

Il ressort de cette expérimentation que l'approche de la prédiction univariée a échoué, non pas à cause d'erreur technique, mais de limitations structurelles.

L'analyse croisée des Articles 2 et 3 révèle trois points de blocages :

- **Rapport Signal/Bruit trop faible** : Les modèles convergent vers des moyennes ou répètent des motifs initiaux. Cela indique que la courbe de prix est dominée par du bruit aléatoire (marche aléatoire) plutôt que par des motifs déterministes exploitables par un réseau de neurones sur cette fenêtre temporelle.
- **Non-stationnarité structurelle** : Un modèle ML suppose que le futur ressemblera statistiquement au passé. Or, l'EDA (Art 2) a montré que le marché crypto change de régime trop vite (cycles semestriels valides en 2022, obsolètes en 2025). Un modèle entraîné peut devenir inutile du jour au lendemain.
- **Déconnexion Plateforme vs Prix** : La pression acheteur/vendeur sur Binance est équilibrée, pourtant le prix global monte. Les mouvements sont initiés ailleurs (institutionnels, OTC).

Conclusion intermédiaire : Le prix est une variable de sortie (*output*) trop dépendante de facteurs externes invisibles dans une série temporelle isolée.

c. Et maintenant ? Passage à un nouveau projet

Face à ce constat, deux voies sont possibles :

- Complexifier la prédiction de prix : Ajouter des variables externes (sentiment, on-chain, macro) pour tenter de capturer les facteurs manquants. C'est une approche valide, bien documentée dans la littérature quantitative.
- Changer de problème : Si le « Quand » (timing) est imprédictible ou hors de portée, alors le « Quoi » (sélection d'actif) devient la variable critique de performance.

C'est vers cette seconde voie que je vais orienter la suite de mes actions.

L'objectif de ce projet a toujours été d'explorer le cryptoverse avec une boussole data. Puisque le prix est la résultante bruitée d'une multitude de facteurs, remontons à la source. Au lieu de prédire la courbe, évaluons la solidité de ce qui la génère : le projet lui-même.

Un choix de positionnement

La recherche sur la prédiction de prix par séries temporelles est un domaine intéressant, mais hautement concurrentiel. En tant que projet solo, ma valeur ajoutée ne se situe pas dans la course à l'optimisation de modèles sur un signal aussi bruité. Mon expertise et mon intérêt se situent dans la compréhension systémique des projets, l'ingénierie de données fiables, et la construction d'outils d'aide à la décision.

Abandonner l'approche prix n'est donc pas seulement une conclusion empirique : c'est aussi un arbitrage conscient. Plutôt que de chercher à prédire quand le marché bouge, je choisis de me concentrer là où se trouve ma plus-value : un problème d'évaluation et de classification, plus aligné avec mes compétences.

Vers un Investissement Assisté

Dans un écosystème où les scams se professionnalisent et où les technologies évoluent rapidement (DePIN, RWA, AI), le risque principal n'est plus seulement la volatilité, mais aussi la fiabilité.

Cet article propose donc un pivot : passer d'une logique de Trading Assisté (prédiction de prix) à une logique d'Investissement Assisté (scoring de fondamentaux).

Nous allons définir comment utiliser les traces numériques laissées par les projets pour construire un système de classification de risque. A l'inverse du prix, ces traces sont des variables d'entrée (inputs) plus stables et observables.

La suite de ce document détaillera l'architecture de ce système de scoring, ouvrant la voie à une série d'articles deep dive consacrés à l'extraction et l'analyse de chacune de ces métriques.

2. Les traces

Contrairement aux projets traditionnels (Web2.0), les projets blockchain possèdent des spécificités structurelles héritées du Bitcoin, qui les rendent particulièrement propices à l'analyse de données :

- La Transparence :
 - On-chain : Toutes les transactions sont publiques et vérifiables sur la blockchain.
 - Technique (Open Source) : La majorité des codes sont publics (ex : GitHub).
 - Feuille de Route (Whitepaper) : Les objectifs sont documentés. Bien que sujet à interprétation, ce texte constitue une base sémantique analysable par NLP (*Natural Language Processing*)
- La Décentralisation : Un projet Web3 ne peut exister sans utilisateurs actifs.

Ces actions forment un socle d'artefacts numériques, mais pour un utilisateur lambda l'analyse de ces indicateurs se fait de manière manuelle et subjective. C'est ici que la Data Science apporte sa valeur ajoutée : transformer des signaux qualitatifs en variables quantitatives objectives.

Contrairement au prix (non-stationnaire, Art 3), ces traces sont des variables d'entrée (inputs) plus stables. Elles ne servent pas à prédire un cours à court terme, mais à classer la probabilité de survie et de succès d'un projet.

Voici les catégories de métriques identifiées pour construire ce système de scoring ainsi que la question qui doit être répondu par chaque catégorie :

- Équipe : « Qui porte le projet et sont-ils crédibles ? »
- Technologie & Code : « Le produit est-il fonctionnel et sécurisé ? »
- Tokenomics & Finance : « La structure économique est-elle viable ? »
- Documentation : « La vision est-elle claire et cohérente ? »
- Communauté : « L'adoption est-elle réelle ou artificielle ? »

Ces catégories posent le cadre de l'analyse. Reste maintenant à définir la méthode pour les transformer en métriques quantifiables et utilisables.

3. La feuille de route

Comme expliqué dans l'Article 2, tout projet d'intelligence artificielle repose sur la qualité des données. C'est le premier défi à surmonter. Pour le Bitcoin, les données de prix sont abondantes et structurées. Pour l'évaluation de projets, la situation est plus complexe : il n'existe pas de dataset de référence labellisé permettant de distinguer objectivement un projet "fiable" d'un projet "risqué".

Contrairement à la prédiction de prix où la vérité terrain est connue a posteriori (le prix futur), évaluer la fiabilité d'un projet est intrinsèquement subjectif. Un projet peut sembler solide et échouer (mauvais timing, macro), ou être un scam sophistiqué et prospérer temporairement.

Face à cette absence de vérité terrain, une approche Big Bang (tout construire d'un coup) serait vouée à l'échec. Je privilégie donc une approche itérative, inspirée des principes de CI/CD (Continuous Integration / Continuous Deployment), adaptée à la Data Science :

a. Deep-Dives Métriques (Recherche & Validation)

Chaque pilier identifié dans la Section 2 fera l'objet d'une exploration dédiée :

- Recherche bibliographique : Accumulation de sources diverses (articles scientifiques, rapports d'industrie, ...) pour identifier des indicateurs validés.
- Publication : Chaque Deep-Dive donnera lieu à un article résumant les insights et les métriques retenues.

b. Développement Outil (Itératif)

Pour chaque métrique, le développement suivra un cycle en trois temps :

- Identification des sources : API GitHub, Etherscan, réseaux sociaux, bases de données de levées de fonds...
- POC (Proof of Concept) : Une version simplifiée pour valider la faisabilité technique et l'accès aux données.
- Enrichissement progressif : Ajout de fonctionnalités (nettoyage, normalisation, scoring) au fur et à mesure des retours.

c. Construction du Dataset (Labelisation Hybride)

- Phase 1 (Manuelle) : Rédaction d'analyses de projets 100% manuelles pour établir une base de vérité terrain initiale et valider la pertinence des métriques choisies.
- Phase 2 (Assistée) : Intégration progressive d'outils d'automatisation avec validation humaine systématique pour limiter les biais.

- Phase 3 (Dataset Évolutif) : Au fur et à mesure que la base grossit, elle servira à entraîner des modèles de classification, dont les performances seront comparées aux analyses manuelles.

d. Transparence et Validation Externe

- Code Open-Source : Tous les scripts d'extraction et de scoring seront publics pour auditabilité.
- Boucle de Feedback : La publication régulière vise à créer une forme de revue par les pairs ouverte, permettant de valider les métriques choisies avant leur intégration au système global.
- Documentation Continue : Chaque étape validée sera documentée (articles, notebooks, code commenté).

Prochaine Étape : Article 6

Cette feuille de route lancée, place à la première mise en œuvre concrète. Le prochain article sera un Deep-Dive sur le Whitepaper, un élément que je trouve passionnant car il cristallise à la fois la vision technique, économique et marketing d'un projet. Nous y explorerons comment transformer ce document qualitatif en métriques quantitatives exploitables via le NLP.